TRABAJO FINAL / LANGCHAIN · LANGGRAPH · RAG

AtteliA

Tu asesora inteligente de moda,
con respuestas respaldadas por documentos.

INTEGRANTE(S): [COMPLETAR]

OCTUBRE 2026

TRABAJO AGENTE

El problema: IA sin evidencia verificable

Preguntas cotidianas

¿Qué colores combinan? ¿Qué calzado conviene? ¿Cómo aprovechar prendas existentes?

Riesgo generativo

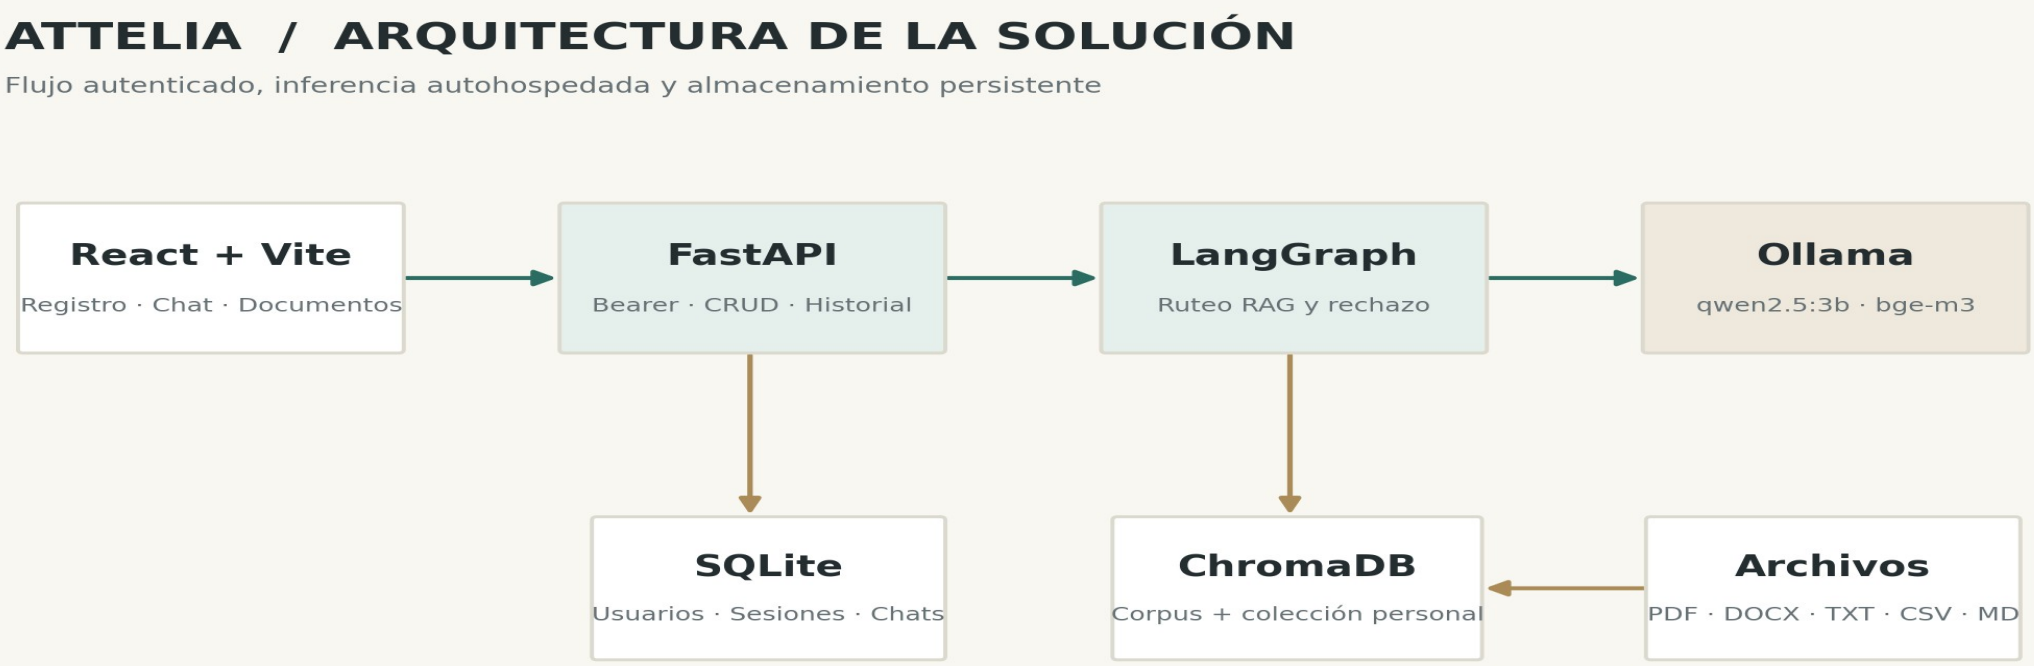
Un asistente puede improvisar consejos sin mostrar de dónde proviene la información.

Propuesta AtteliA

Responder con documentos recuperados, citar fuentes y rechazar cuando no haya sustento.

OBJETIVO → Consulta confiable y base de conocimiento ampliable.

Arquitectura: web + agente + modelo local



Seguridad: autenticación en API · Aislamiento por usuario · Modelo local · HTTPS en despliegue

Stack: componentes especializados

FRONTEND

React + Vite

Experiencia conversacional

BACKEND

FastAPI + SQLite

REST, usuarios e historial

GRAFO

LangGraph + LangChain

Decisiones y herramientas

LLM LOCAL

Ollama · qwen2.5:3b

Generación en servidor propio

EMBEDDINGS

bge-m3

Representaciones vectoriales

RETRIEVAL

ChromaDB

Índice y fuentes persistentes

LangGraph: responder o rechazar



Estrategias: distancia máxima configurable · solapamiento de términos · nodo de rechazo · prompt restringido · fuentes.

Nota: no es garantía absoluta; validar con preguntas positivas y negativas después de indexar.

Ruta crítica: si NO hay contexto suficiente, la generación no se ejecuta.

RAG incremental y base de conocimiento

01 · Ingesta

PDF · DOCX · TXT · Markdown · CSV. Extracción y fragmentación de texto.

02 · Embeddings

bge-m3 convierte fragmentos en vectores; ChromaDB los persiste por usuario.

03 · Recuperación

Similitud + filtro léxico + umbral y fuentes. Sin evidencia → rechazo.

Corpus base: 6 volúmenes + documentos privados por cuenta

Seguridad: cada usuario, sus documentos

Autenticación

Registro y login; contraseñas con scrypt y salt; sesión Bearer; expiración a los siete días.

Autorización

API protegida; historial por usuario; metadatos SQLite; índices Chroma personales.

Producción: HTTPS con Caddy · credenciales fuera de Git · Ollama no expuesto.

Demostración en vivo: tres escenarios

A · Respuesta válida

Preguntar qué es un armario cápsula. Mostrar respuesta y nombre de la fuente.

B · Rechazo explícito

Preguntar quién ganó el Mundial de 2022. Mostrar que AtteliA no genera sin contexto.

C · Archivo nuevo

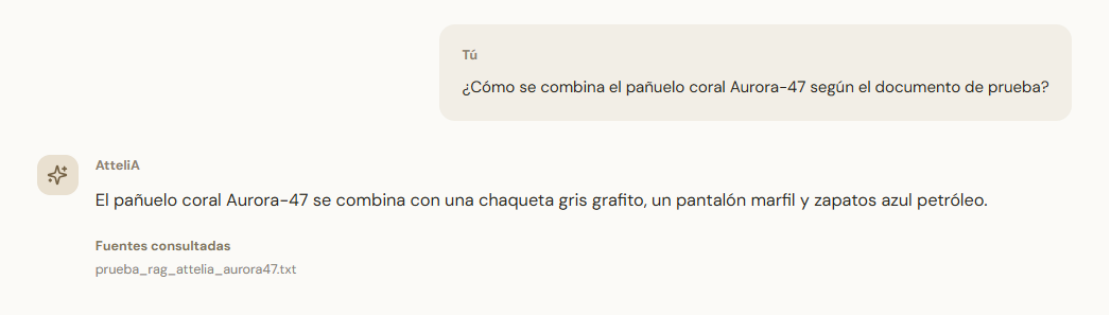
Subir prueba_rag_attelia_aurora47.txt y preguntar por Aurora-47. Mostrar su fuente.

Evidencia: capturar los resultados reales en Ubuntu y/o dominio público.

EVIDENCIAS REALES

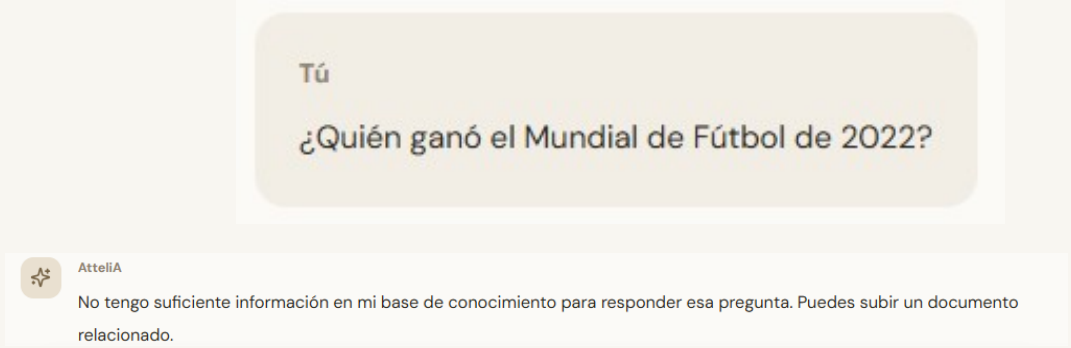
Pruebas funcionales verificadas

RAG documental: Aurora-47



Carga TXT -> recuperación del documento -> respuesta exacta con fuente.

Rechazo sin evidencia



Pregunta sobre el Mundial de 2022 -> rechazo por ausencia de contexto.

Pruebas efectuadas localmente en Ubuntu/WSL con Ollama. Despliegue público aún pendiente.

Despliegue: listo para publicar, pendiente de verificar

Preparación incluida

Dockerfiles de frontend/backend, Compose con Ollama y Caddy, persistencia y guía paso a paso.

Acciones del equipo

Crear GitHub, configurar VPS + DNS, iniciar contenedores, indexar y probar HTTPS.

URL frontend: [PENDIENTE] | **URL backend: [PENDIENTE]**

Conclusiones y siguientes verificaciones

Logros del desarrollo

- Arquitectura RAG codificada
- Carga documental personalizada
- Rechazo cuando faltan fuentes
- Autenticación y controles de acceso

Para la entrega

- Ollama probado en WSL
- Calibrar la búsqueda
- Evidencias ya capturadas
- Publicar URL y GitHub

ATTELIA · RESPUESTAS RESPONSABLES BASADAS EN DOCUMENTOS