TRABAJO FINAL / LANGCHAIN · LANGGRAPH · RAG

AtteliA

Tu asesora inteligente de moda,
con respuestas respaldadas por documentos.

STEFANY HURTADO MARIN / IMPLEMENTACIÓN DE SOFTWARE

OCTUBRE 2026

TRABAJO AGENTE

El problema: IA sin evidencia verificable

Preguntas cotidianas

¿Qué colores combinan? ¿Qué calzado conviene? ¿Cómo aprovechar prendas existentes?

Riesgo generativo

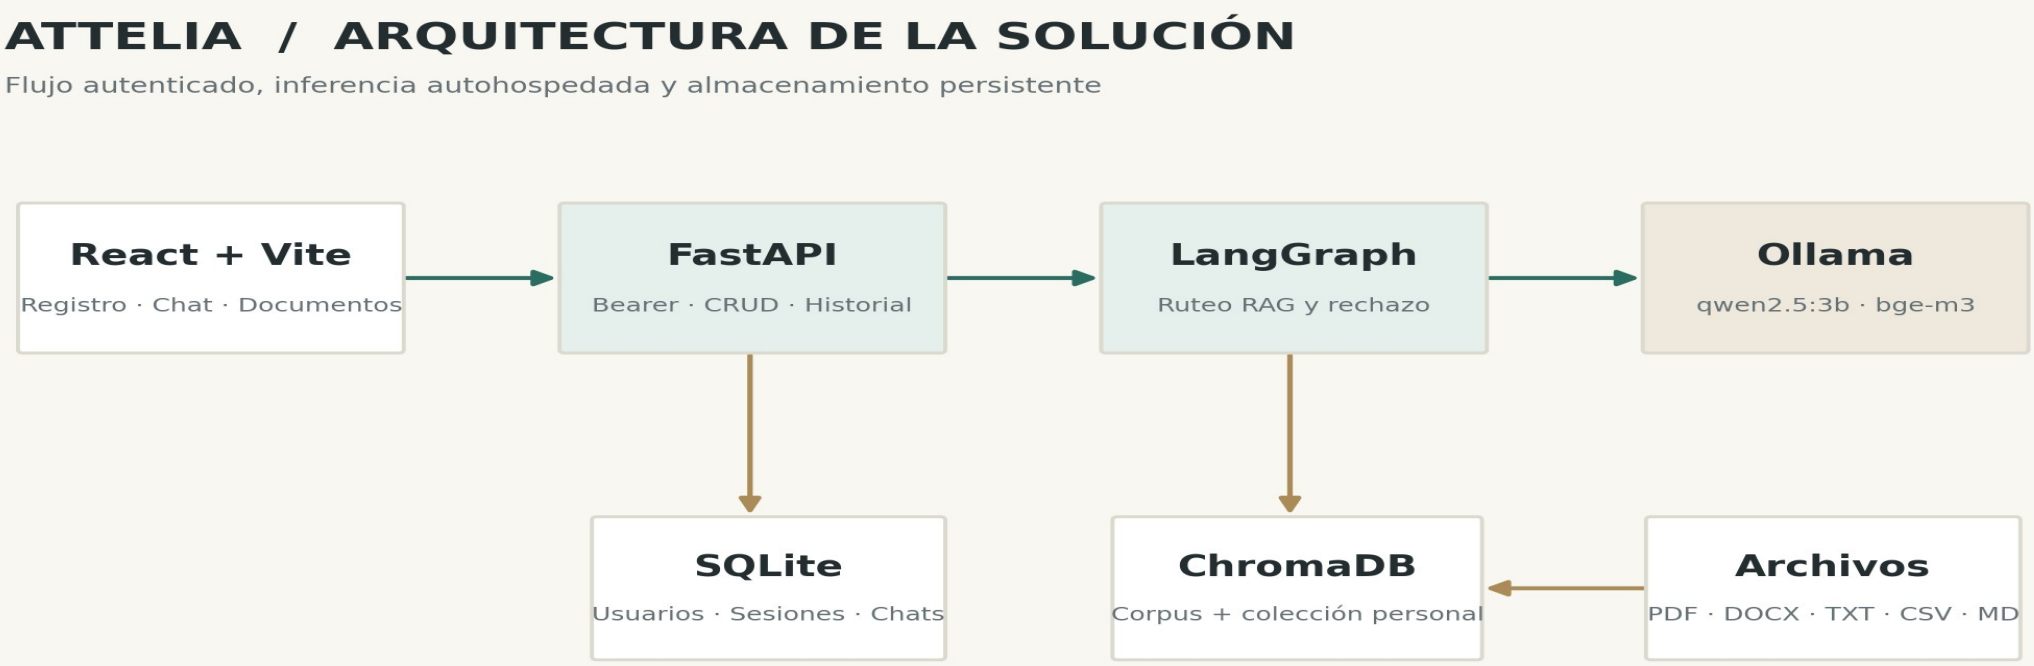
Un asistente puede improvisar consejos sin mostrar de dónde proviene la información.

Propuesta AtteliA

Responder con documentos recuperados, citar fuentes y rechazar cuando no haya sustento.

OBJETIVO → Consulta confiable y base de conocimiento ampliable.

Arquitectura: web + agente + modelo local



Seguridad: autenticación en API · Aislamiento por usuario · Modelo local · HTTPS en despliegue

Stack: componentes especializados

FRONTEND

React + Vite

Experiencia conversacional

BACKEND

FastAPI + SQLite

REST, usuarios e historial

GRAFO

LangGraph + LangChain

Decisiones y herramientas

LLM LOCAL

Ollama · qwen2.5:3b

Generación en servidor propio

EMBEDDINGS

bge-m3

Representaciones vectoriales

RETRIEVAL

ChromaDB

Índice y fuentes persistentes

LangGraph: responder o rechazar



Estrategias: distancia máxima configurable · solapamiento de términos · nodo de rechazo · prompt restringido · fuentes.

Nota: no es garantía absoluta; validar con preguntas positivas y negativas después de indexar.

Ruta crítica: si NO hay contexto suficiente, la generación no se ejecuta.

RAG incremental y base de conocimiento

01 · Ingesta

PDF · DOCX · TXT · Markdown · CSV. Extracción y fragmentación de texto.

02 · Embeddings

bge-m3 convierte fragmentos en vectores; ChromaDB los persiste por usuario.

03 · Recuperación

Similitud + filtro léxico + umbral y fuentes. Sin evidencia → rechazo.

Corpus base: 6 volúmenes + documentos privados por cuenta

Seguridad: cada usuario, sus documentos

Autenticación

Registro y login; contraseñas con scrypt y salt; sesión Bearer; expiración a los siete días.

Autorización

API protegida; historial por usuario; metadatos SQLite; índices Chroma personales.

Producción: HTTPS con Caddy · credenciales fuera de Git · Ollama no expuesto.

Demostración en vivo: tres escenarios

A · Respuesta válida

Preguntar qué es un armario cápsula. Mostrar respuesta y nombre de la fuente.

B · Rechazo explícito

Preguntar quién ganó el Mundial de 2022. Mostrar que AtteliA no genera sin contexto.

C · Archivo nuevo

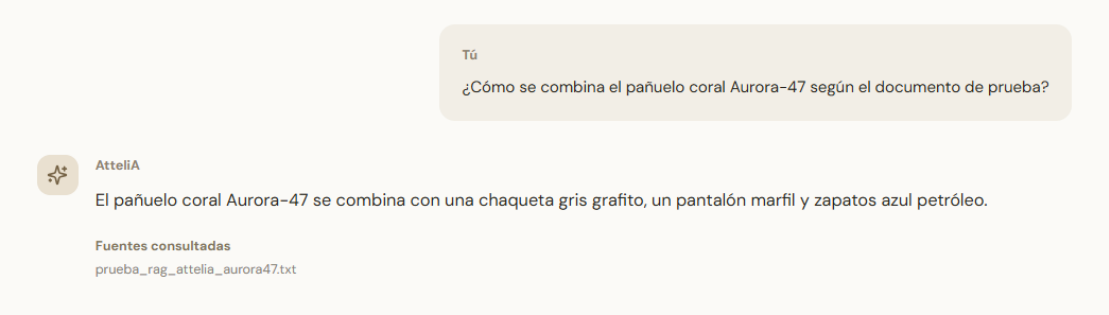
Subir prueba_rag_attelia_aurora47.txt y preguntar por Aurora-47. Mostrar su fuente.

Evidencia: capturar los resultados reales en Ubuntu y/o dominio público.

EVIDENCIAS REALES

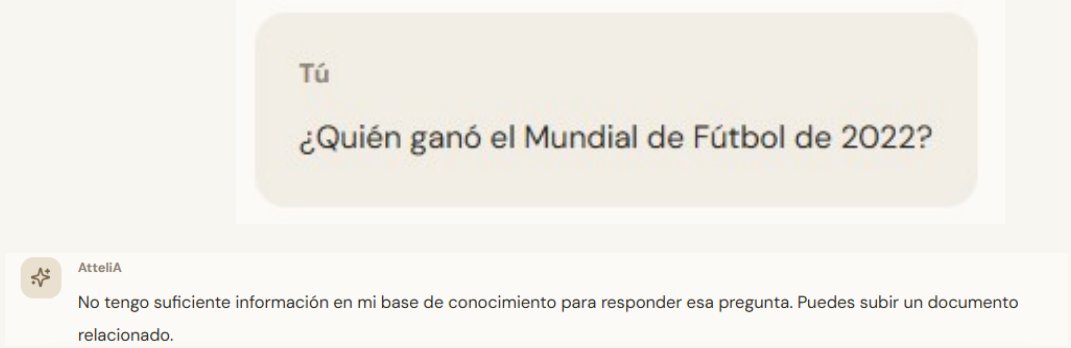
Pruebas funcionales verificadas

RAG documental: Aurora-47



Carga TXT -> recuperación del documento -> respuesta exacta con fuente.

Rechazo sin evidencia



Pregunta sobre el Mundial de 2022 -> rechazo por ausencia de contexto.

Pruebas en Ubuntu/WSL con Ollama; acceso remoto temporal verificado por Cloudflare.

Publicación temporal HTTPS: probada

Arquitectura publicada

React y API integrados en el puerto 8080, publicados con Cloudflare Quick Tunnel desde Ubuntu/WSL.

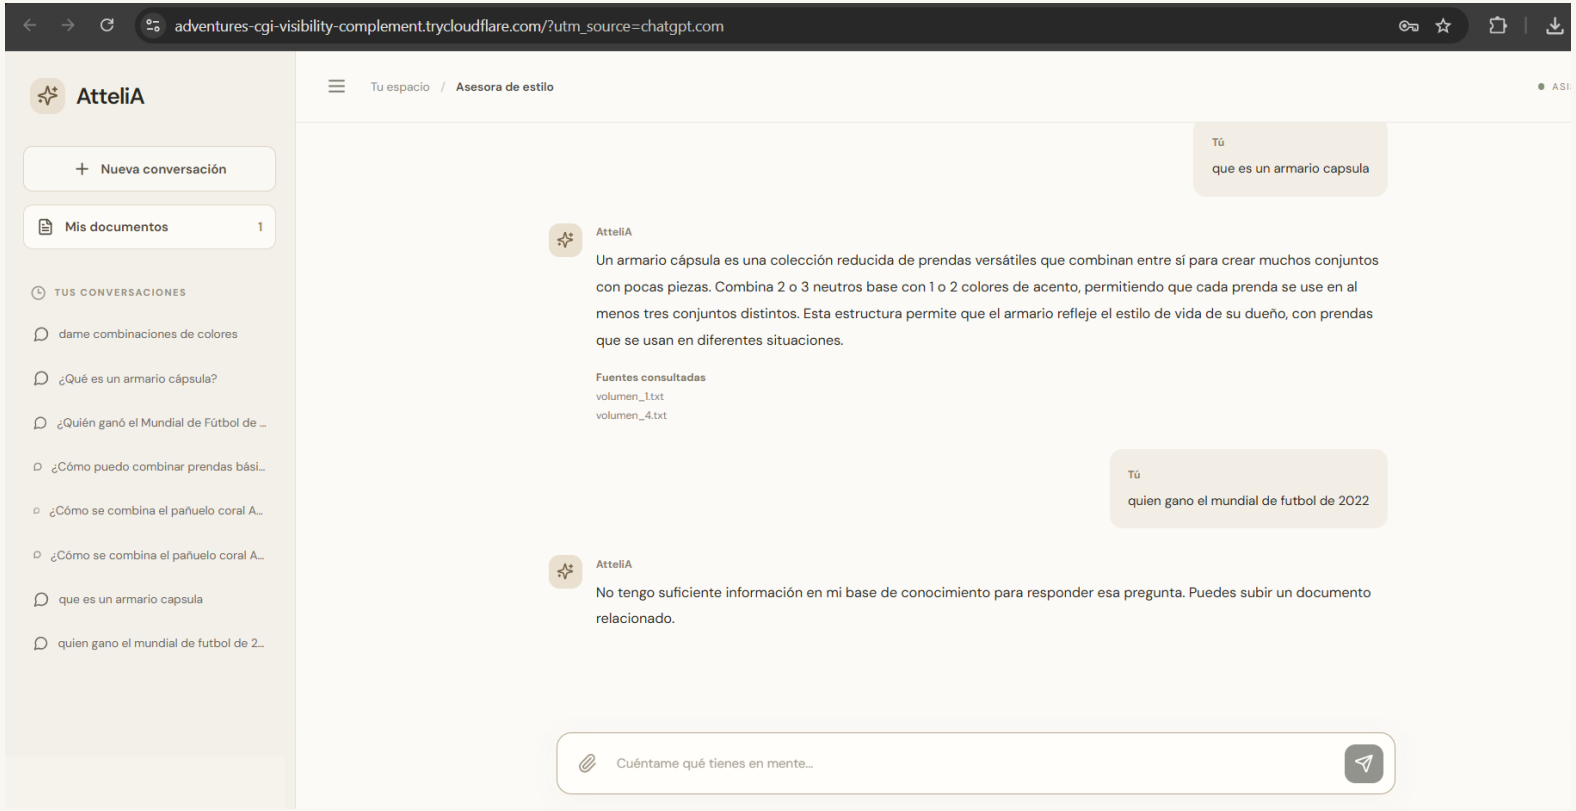
Evidencia y límite

GitHub público y acceso desde PC y celular confirmados. Oracle Always Free no disponible (AD-1).

URL temporal: adventures-cgi-visibility-complement.trycloudflare.com

Acceso desde Internet: PC + celular

Cloudflare Quick Tunnel permite acceder desde fuera de la red local; el servicio sigue en Ubuntu.





GitHub: github.com/mefaHurtado/attelia-ia

URL HTTPS temporal: adventures-cgi-visibility-complement.trycloudflare.com · La nube permanente continúa pendiente.

Conclusiones y alcance real

Logros del desarrollo

- Arquitectura RAG codificada
- Carga documental personalizada
- Rechazo cuando faltan fuentes
- Autenticación y controles de acceso

Para la entrega

- GitHub publicado
- HTTPS temporal probado
- Acceso desde celular
- Cloud permanente pendiente

ATTELIA · RESPUESTAS RESPONSABLES BASADAS EN DOCUMENTOS